

实验一差异表达分析

Yuchen Gao

March 2026

1 实验目的

1. 了解 RNA-seq 的基本原理以及流程
2. 了解基因差异表达分析的基本原理以及方法
3. 了解假设检验原理与方法
4. 了解多重假设检验校正原理与方法
5. 掌握 DESeq2 工作流并实践

2 背景介绍

2.1 RNA-seq

RNA 测序技术 (RNA-seq) 通过二代测序 (NGS) 技术检查样本中 RNA 的数量和序列。此技术能够分析转录组，揭示在特定条件下（如肿瘤 vs 正常组织）基因的开启、关闭状态及其表达水平。通过对比不同条件下的样本，研究者可以识别出由于生物学处理或疾病状态引起的基因表达变化。

2.2 DEG

基因差异表达 (Differential gene expression, DEG) 旨在将获得的 RNA-seq 结果进行分析，将多个实验组进行比较，以找出在不同条件下哪些基因/转录本发生了显著变化，例如癌细胞与正常细胞、药物处理组与对照组等等。

在 DEG 分析中, Fold Change (FC) 是一个核心指标, 用于衡量某个基因在两个不同条件之间表达量的变化大小, 其计算方法为: $FC = \frac{B}{A}$ (其中 B 为实验组某基因平均表达量, A 为对照组该基因平均表达量)。通常表示为 $\log_2 FC$, 以令数据更具有对称性, 分布更接近正态分布, 便于可视化。

进一步地, p 值用于衡量所得到的不同基因的表达量是否具有显著性差异。 $p < 0.05$ 被认为差异由随机误差导致的概率很低, 因此两组中的基因显著差异表达。然而在处理较大的基因数量时, 为防止出现的假阳性情况, 将对结果进行多重检验校正, 从而获得 *p*adj, 控制假阳性所占比例

2.3 TCGA

癌症基因组图谱 (TCGA) 是由美国国家癌症研究所 (NCI) 和国家人类基因组研究所 (NHGRI) 于 2006 年联合启动的一项宏大计划, 对 33 种不同类型的癌症进行系统的基因组表征。在这套数据中, 不仅包含 RNA-Seq (转录组), 还包括 DNA 测序 (突变)、甲基化、蛋白质组学 (RPPA) 和临床数据 (生存期、病理分期)。TCGA 研究网络已对大量人类肿瘤进行了特征分析, 旨在揭示 DNA、RNA、蛋白质及表观遗传层面的分子异常。

在本实验中, 我们准备利用 TCGA 数据组中的 RNA-seq 的数据组, 进行 DEG 分析的练习

3 实验方法

3.1 选择肝细胞癌数据集进行 DEG 分析练习

由上所述, 考虑到数据集对照组严格、标准数据层级以及样本量庞大的特点, 使用 TCGA 中的 LIHC (Liver Hepatocellular Carcinoma, 肝细胞癌) 数据集进行 DEG 分析练习。

本数据集在 TCGA 的所有癌种中, RNA-Seq 数据质量相对稳定, 测序深度较深, 且受到的样本降解干扰相对较小。更重要的是, LIHC 是 GEPIA3 等在线工具支持最完善的癌种之一, 这意味着在 R 语言里算出的结果, 可以立即在 GEPIA3 网页端进行二次验证。

3.2 使用 Bioconductor、tidyverse 软件包

Bioconductor 是全球生物信息学领域的开源软件工程，用于转录组 (RNA-seq)、单细胞或基因组分析，在本次分析练习中，利用了 Bioconductor 中 org.Hs.eg.db、DESeq2、EnhancedVolcano 的软件包。

- DESeq2(1.50.2): 基因差异表达分析的核心算法
- org.Hs.eg.db(3.22.0): 人类基因注释数据库，用来翻译基因 ID，进行更好的可视化处理
- EnhancedVolcano(1.28.2): 用于绘制火山图

tidyverse(2.0.0) 软件包用于整理基因的表达数据，为进行基因差异表达分析提供所需的表格

3.3 命令、参数的意义

3.3.1 安装软件包

```
1 if (!require("BiocManager")) install.packages("BiocManager")
2 BiocManager::install("The_software_packages_you_need")

1 install.packages()
```

3.3.2 数据读取与预处理

```
1
2 raw <- read.csv() # 读取文件
3 matrix_1 <- as.matrix() # 转换为 matrix 并命名
4 rownames(matrix_1) <- raw[]
5 cts <- round() # 数据转换
```

3.3.3 制作 DEG 分析所需表格

```
1 tcga_id <- colnames() # 获得基因名称
2 code <- substr() # 获得状态信息
3 condition <- ifelse()
4 condition <- factor() # 将 condition 转换为 factor
5 colData <- data.frame() # 制作样本类型数据框
```

3.3.4 数据预处理与差异分析

```
1 dds <- DESeqDataSetFromMatrix(countData = , colData = , design = ) # 构建差异分析数据集对象, design指定比较的实验因素
2 keep <- rowSums(counts(dds) )>= # 筛选总count>=10的基因
3 dds <- dds[keep,] # 使得dds里只包括有效表达的基因
4 dds <- DESeq(dds) # 执行差异表达分析
5 res <- results(dds, contrast=) # 提取对比结果
```

3.3.5 结果整理

```
1 resOrdered <- res[order(),] # 对结果 res 进行排列
2 summary()
```

3.3.6 结果可视化

基因 ID 转换

```
1 res_df <- as.data.frame() %>% rownames_to_column() # 将 DESeq2 的结果转为数据框, 将行名变为列名
2 res_df$ENSEMBL_clean <- gsub() # 去掉 Ensembl ID 中的版本号, 方便后续匹配数据库
3 gene_map <- bitr() # 转化为基因名称
```

绘图参数定义

```
1 # 定义筛选阈值
2 cut_off_pvalue =
3 cut_off_logFC =
4 # 提取最显著的15个基因方便后期标注
5 select_genes <- res_final %>%
6   filter() %>%
7   arrange() %>%
8   head() %>%
9   pull()
```

绘制火山图

```
1 EnhancedVolcano()
```

4 实验结果

4.1 完整代码

```

1 # --- 1. 环境准备 ---
2 if (!require("BiocManager", quietly = TRUE))
3   install.packages("BiocManager")
4 BiocManager::install(version = "3.22")
5 BiocManager::install(c("GenomicFeatures", "AnnotationDbi"))
6 BiocManager::install("DESeq2")
7 BiocManager::install("org.Hs.eg.db")
8 BiocManager::install("EnhancedVolcano")
9
10
11 library(DESeq2)
12 library(tidyverse)
13 library(org.Hs.eg.db)
14 library(EnhancedVolcano)
15 library(ggplot2)
16 library(ggrepel)
17
18 packageVersion("DESeq2")
19 packageVersion("tidyverse")
20 packageVersion("org.Hs.eg.db")
21 packageVersion("EnhancedVolcano")
22
23 # --- 2. 数据读取与预处理 ---
24 raw <- read.csv("/Users/gaoyuchen/Downloads/TCGA-LIHC.star_counts (1).tsv",
25   sep = "\t")
26 matrix_1 <- as.matrix(raw[, -1])
27 rownames(matrix_1) <- raw[, 1]
28 cts <- round(2^matrix_1 - 1)
29
30 # --- 3. 构建分组信息 ---
31 tcga_id <- colnames(cts)
32 code <- substr(tcga_id, 14, 14)
33 condition <- ifelse(as.numeric(code) < 1, "tumor", "normal")
34 condition <- factor(condition, levels = c("normal", "tumor"))
35
36 colData <- data.frame(row.names = tcga_id, tcga_id=tcga_id, code = code,
37   condition = condition)
38
39 # --- 4. 差异分析 ---
40 dds <- DESeqDataSetFromMatrix(countData = cts, colData = colData, design = ~
41   condition)
42 keep <- rowSums(counts(dds)) >= 10
43 dds <- dds[keep,]
44 dds <- DESeq(dds)
45 res <- results(dds, contrast=c("condition", "tumor", "normal"))
46 res

```

```

44
45 # ---5. 整理结果 ---
46 resOrdered <- res[order(res$pvalue),]
47 summary(res)
48 resOrdered
49
50 # --- 6. ID 转换与去重 ---
51 res_df <- as.data.frame(res) %>%
52   rownames_to_column("ENSEMBL_full") %>%
53   mutate(ENSEMBL_clean = gsub("\\..*", "", ENSEMBL_full))
54
55 gene_map <- bitr(res_df$ENSEMBL_clean,
56                 fromType = "ENSEMBL",
57                 toType = "SYMBOL",
58                 OrgDb = org.Hs.eg.db,
59                 drop = FALSE)
60
61 res_final <- res_df %>%
62   inner_join(gene_map, by = c("ENSEMBL_clean" = "ENSEMBL")) %>%
63   filter(!is.na(SYMBOL))
64
65 res_final
66
67 # --- 7. 绘图参数定义 ---
68 cut_off_pvalue = 1e-5
69 cut_off_logFC = 2
70
71 select_genes <- res_final %>%
72   filter(!is.na(padj)) %>%
73   filter(padj < cut_off_pvalue & abs(log2FoldChange) > cut_off_logFC) %>%
74   arrange(padj) %>%
75   mutate(direction = ifelse(log2FoldChange > 0, "up", "down")) %>%
76   group_by(direction) %>%
77   slice_head(n = 5) %>%
78   ungroup() %>%
79   pull(SYMBOL)
80
81 # --- 7. 最终绘图 ---
82 EnhancedVolcano(res_final,
83                 lab = res_final$SYMBOL,
84                 x = "log2FoldChange",
85                 y = "padj",
86                 selectLab = select_genes,
87                 pCutoff = cut_off_pvalue,
88                 FCcutoff = cut_off_logFC,
89                 arrowheads = FALSE,

```

```

90         drawConnectors = TRUE,
91         widthConnectors = 0.8,
92         colConnectors = 'grey10',
93         lengthConnectors = unit(10, 'mm'),
94         max.overlaps = 20,
95         pointSize = 1.0,
96         labSize = 3.5,
97         labCol = 'black',
98         labFace = 'bold',
99         xlab = bquote(~Log[2]~ "Fold Change"),
100        ylab = bquote(~Log[10]~italic(P)),
101        xlim = c(-10, 10),
102        ylim = c(0, max(-log10(res_final$padj), na.rm = TRUE) + 5),
103        legendLabels = c("NS", "Log2 FC", "P-value", "P-value & Log2
104                          FC"),
105        legendPosition = "top",
106        legendLabSize = 10,
107        title = "Volcano Plot: Tumor vs Normal",
108        subtitle = paste0("Total genes: ", nrow(res_final)),
109    )
110    library(dplyr)
111    res_classified <- res_final %>%
112      mutate(group = case_when(
113        padj < cut_off_pvalue & log2FoldChange > cut_off_logFC ~ "Up",
114        padj < cut_off_pvalue & log2FoldChange < -cut_off_logFC ~ "Down",
115        padj < cut_off_pvalue & abs(log2FoldChange) <= cut_off_logFC ~ "P_only",
116        padj >= cut_off_pvalue & abs(log2FoldChange) > cut_off_logFC ~ "FC_only"
117      ),
118      TRUE ~ "NS"
119    )
120    gene_counts <- table(res_classified$group)
121    print(gene_counts)
122
123
124    # 提取上调基因的所有参数，并按显著性(padj)排序
125    up_table <- res_classified %>%
126      filter(group == "Up") %>%
127      select(SYMBOL, log2FoldChange, pvalue, padj) %>%
128      arrange(padj)
129
130    # 提取下调基因的所有参数，并按显著性(padj)排序
131    down_table <- res_classified %>%
132      filter(group == "Down") %>%
133      select(SYMBOL, log2FoldChange, pvalue, padj) %>%

```

```

134     arrange(padj)
135
136     print(head(up_table, 10))
137     print(head(down_table, 10))
138
139     write.csv(head(up_table, 10),
140               file = "/Users/gaoyuchen/Downloads/Top50_Up_Genes.csv",
141               row.names = FALSE)
142     write.csv(head(down_table, 10),
143               file = "/Users/gaoyuchen/Downloads/Top50_Down_Genes.csv",
144               row.names = FALSE)

```

4.2 安装所需包并载入

在代码 1-20 行完成了对于 Bioconductor 中 DESeq2、org.Hs.eg.db 以及 EnhancedVolcano 的安装，完成了 tidyverse 包的安装，并且成功展示其版本号

```

> library(DESeq2)
> library(tidyverse)
> library(org.Hs.eg.db)
> library(EnhancedVolcano)
> packageVersion("DESeq2")
[1] '1.50.2'
> packageVersion("tidyverse")
[1] '2.0.0'
> packageVersion("org.Hs.eg.db")
[1] '3.22.0'
> packageVersion("EnhancedVolcano")
[1] '1.28.2'

```

图 1: 运行截图 1

经过查验发现，所有软件包均处于当前 Bioconductor 稳定发行版的最新状态

4.3 导入数据以及数据转换

从[TCGA 网站](#)下载表达量数据并解压缩，然后通过代码 21-26 行，完成了数据的导入，数据框命名为 raw。注意到官网给出，数据经过了 $\log_2(count+1)$ 的处理，因此再通过实验方法中的命令行将数据转换为真正的基因表达量。


```
> # --- 2. 数据读取与预处理 ---
> raw <- read.csv("~/Users/guoyuchen/Downloads/TCGA-LIHC_star_counts.tsv", sep = "\t")
> matrix_1 <- as.matrix(raw[, -1])
> rownames(matrix_1) <- raw[, 1]
> cts <- round(2*matrix_1 - 1)
```

图 2: 运行截图 2

raw	60660 obs. of 425 variables
-----	-----------------------------

图 3: 结果截图

cts	Large matrix (25719840 elements, 211.1 MB)
-----	--

图 4: 结果截图

4.4 生成样本类型数据框

想要进行 DEG 分析，需要在有 cts 表格后，附加一个记录不同样本所对应状态的样本类数据框，在代码 27-32 行，完成了样本类数据框的生成。在这段代码中，成功提取了基因 ID，并根据 TCGA 命名规范提取 ID 的第 14 位字符并利用其定义样本类型。进一步地，将字符向量转换为因子，并显式设置参考水平，以便于后续直接以 Normal 状态为对照组进行分析。

	TCGA.SRAA1C.01A	TCGA.ED.A66Y.01A	TCGA.DD.AAEL.01A	TCGA.ED.A80S.01A
ENSG000000000003.15	3672	2349	3277	4285
ENSG0000000000005.6	2	0	1	3
ENSG000000000419.13	1009	1084	880	668
ENSG000000000457.14	448	1173	254	1287
ENSG000000000460.17	881	285	83	320
ENSG000000000938.13	31	112	207	157
ENSG000000000971.16	35998	1759	39644	38238
ENSG00000001036.14	456	2463	3484	1676
ENSG00000001084.13	4029	1078	4361	10952
ENSG00000001167.14	417	1354	631	3886
ENSG00000001460.18	66	269	94	131
ENSG00000001461.17	138	620	330	340
ENSG00000001497.18	1608	2044	1826	1792
ENSG00000001561.7	20	936	25	1525
ENSG00000001617.12	203	1345	562	1255
ENSG00000001626.16	8	1	1	2

图 5: cts

	tcga_id	code	condition
TCGA.5R.AA1C.01A	TCGA.5R.AA1C.01A	0	tumor
TCGA.ED.A66Y.01A	TCGA.ED.A66Y.01A	0	tumor
TCGA.DD.AAEI.01A	TCGA.DD.AAEI.01A	0	tumor
TCGA.ED.A8O5.01A	TCGA.ED.A8O5.01A	0	tumor
TCGA.DD.A3A2.11A	TCGA.DD.A3A2.11A	1	normal
TCGA.DD.AACH.01A	TCGA.DD.AACH.01A	0	tumor
TCGA.FV.A3R3.01A	TCGA.FV.A3R3.01A	0	tumor
TCGA.G3.A5SJ.01A	TCGA.G3.A5SJ.01A	0	tumor
TCGA.HP.A5MZ.01A	TCGA.HP.A5MZ.01A	0	tumor
TCGA.ZP.A9D0.01A	TCGA.ZP.A9D0.01A	0	tumor
TCGA.BC.A10W.01A	TCGA.BC.A10W.01A	0	tumor
TCGA.DD.A4NH.01A	TCGA.DD.A4NH.01A	0	tumor
TCGA.G3.A25Z.01A	TCGA.G3.A25Z.01A	0	tumor
TCGA.DD.A39Z.11A	TCGA.DD.A39Z.11A	1	normal
TCGA.DD.AACX.01A	TCGA.DD.AACX.01A	0	tumor
TCGA.BC.A10X.01A	TCGA.BC.A10X.01A	0	tumor

图 6: colData

4.5 构建 DESeqDataSet，预过滤以及差异分析

此过程由代码第 35-41 行完成。构建 DESeqDataSet，旨在将基因表达矩阵、样本类型数据框以及实验设计打包，是后续进行 DEG 处理的必经之路。

之后，成功筛选总 count>=10 的基因并保留，其意义在于剔除测序噪声，筛选后更新原始数据。

最后进行差异分析，并将结果储存在 res 中。

```
> dds <- DESeqDataSetFromMatrix(countData = cts, colData = colData, design = ~ condition)
converting counts to integer mode
> keep <- rowSums(counts(dds)) >= 10
> dds <- dds[keep,]
> dds <- DESeq(dds)
estimating size factors
estimating dispersions
gene-wise dispersion estimates
mean-dispersion relationship
final dispersion estimates
fitting model and testing
-- replacing outliers and refitting for 1997 genes
-- DESeq argument 'minReplicatesForReplace' = 7
-- original counts are preserved in counts(dds)
estimating dispersions
fitting model and testing
> res <- results(dds, contrast=c("condition", "tumor", "normal"))
> res
log2 fold change (MLE): condition tumor vs normal
Wald test p-value: condition tumor vs normal
DataFrame with 35704 rows and 6 columns
      baseMean log2FoldChange      lfcSE      stat      pvalue      padj
      <numeric>      <numeric>      <numeric>      <numeric>      <numeric>      <numeric>
ENSG00000023171.18      335.397      0.794461      0.244181      3.25357      1.13963e-03      2.11846e-03
ENSG00000003240.15      1652.480      1.708740      0.220784      8.14706      3.72868e-16      1.03417e-14
ENSG000000023171.18      335.397      0.794461      0.244181      3.25357      1.13963e-03      2.11846e-03
ENSG000000023171.18      335.397      0.794461      0.244181      3.25357      1.13963e-03      2.11846e-03
ENSG000000022976.15      199.895      0.374555      0.127929      2.92782      3.41342e-03      5.96976e-03
...
ENSG000000007376.8      821.821      0.793699      0.121429      6.53632      6.30510e-11      9.76015e-10
ENSG00000002933.9      39906.759      -0.348629      0.175134      -1.99064      4.65202e-02      6.80120e-02
ENSG000000023171.18      335.397      0.794461      0.244181      3.25357      1.13963e-03      2.11846e-03
ENSG000000005075.15      2223.604      0.477046      0.144113      3.31022      9.32227e-04      2.11846e-03
ENSG000000007520.4      1550.063      0.421583      0.120924      3.48635      4.89658e-04      1.98980e-03
```

图 7: 运行截图以及 res 成果展示

4.6 可视化处理

4.6.1 ID 转换

为方便后续对应基因以及可视化展示时对重要基因进行标记，在求助 AI 工具后，将基因 ID 转换为基因名称。

具体的 ID 转换代码如下：

```
1 res_df <- as.data.frame(res) %>%
2   rownames_to_column("ENSEMBL_full") %>%
3   mutate(ENSEMBL_clean = gsub("\\..*", "", ENSEMBL_full))
4
5 gene_map <- bitr(res_df$ENSEMBL_clean,
6                 fromType = "ENSEMBL",
7                 toType = "SYMBOL",
8                 OrgDb = org.Hs.eg.db,
9                 drop = FALSE)
10
11 res_final <- res_df %>%
12   inner_join(gene_map, by = c("ENSEMBL_clean" = "ENSEMBL")) %>%
13   filter(!is.na(SYMBOL))
14
15 res_final
```

	padj	ENSEMBL_clean	SYMBOL
1	1.391591e-01	ENSG00000000003	TSPAN6
2	1.460688e-02	ENSG00000000005	TNMD
3	8.384706e-01	ENSG000000000419	DPM1
4	5.380136e-01	ENSG000000000457	SCYL3
5	1.120771e-07	ENSG000000000460	FIRRM
6	2.023636e-07	ENSG000000000938	FGR
7	2.489712e-03	ENSG000000000971	CFH
8	4.297156e-02	ENSG000000001036	FUCA2
9	3.242089e-05	ENSG000000001084	GCLC
10	2.007228e-09	ENSG000000001167	NFYA
11	2.533822e-06	ENSG000000001460	STPG1
12	3.655061e-05	ENSG000000001461	NIPAL3
13	1.375328e-08	ENSG000000001497	LAS1L
14	2.031129e-01	ENSG000000001561	ENPP4
15	3.479967e-36	ENSG000000001617	SEMA3F
16	2.495195e-04	ENSG000000001626	CFTR
17	2.104935e-01	ENSG000000001629	ANKIB1
18	6.551064e-01	ENSG000000001630	CYP51A1
19	2.938568e-04	ENSG000000001631	KRIT1
20	3.760778e-05	ENSG000000002016	RAD52
21	1.084549e-01	ENSG000000002330	BAD
22	1.577758e-11	ENSG000000002549	LAP3
23	6.317163e-01	ENSG000000002586	CD99
24	7.126905e-01	ENSG000000002587	HS3ST1
25	6.799831e-08	ENSG000000002726	AOC1
26	9.562944e-02	ENSG000000002745	WNT16
27	1.545596e-03	ENSG000000002746	HECW1
28	8.224344e-01	ENSG000000002822	MAD1L1
29	1.111115e-07	ENSG000000002834	LASP1
30	6.639974e-07	ENSG000000002919	SNX11
31	1.268708e-02	ENSG000000002933	TMEM176A
32	3.776070e-02	ENSG000000003056	M6PR
33	2.183833e-01	ENSG000000003096	KLHL13
34	4.257332e-02	ENSG000000003137	CYP26B1
35	1.035921e-01	ENSG000000003147	ICA1
36	4.945562e-13	ENSG000000003249	DBNDD1
37	9.317510e-06	ENSG000000003393	ALS2
38	1.963184e-01	ENSG000000003400	CASP10
39	7.179243e-08	ENSG000000003402	CFLAR
40	2.514462e-01	ENSG000000003436	TFPI

图 8: 去重后成果

4.6.2 绘图参数定义

为了使火山图能够展现出更多信息，需要在绘图前定义需要的参数。

定义 $cut_{off} p_{value} = 10^{-5}$ 提高对于差异显著的要求，极大降低了选择基因的假阳性情况

定义 $cut_{off} logFC = 2$ 有助于选择在癌症情况下表达量变化更为显著的基因，提高选择基因的生物学意义

结合这两个参数，可以选择出最符合目标的 15 个基因，并将其标注在形成的火山图上。选出的 15 个基因不仅受上述两个参数限制，同时是在此基础上 padj 值最小的 15 个基因。其呈现方式用基因名称。

```
> select_genes
[1] "GABRD" "PLVAP" "CDKN3" "CDC25C" "UBE2T" "CENPF" "NUF2" "SKA1"
[9] "ZIC2" "TROAP" "KIFC1" "BIRC5" "KIF4A" "HJURP" "ARHGEF39"
```

图 9: 选择结果

4.6.3 最终绘图

利用已经生成的参数进行火山图的绘制，代码中实现对于重要基因展示的要求，画出重要的筛选界限，并给处在不同区域的基因点分别标出颜色。




图 10: 火山图

在绘图基础之上，可以对基因进行进一步统计。在询问 AI 进行附加代码部分的学习后，对于不同类型的基因进行了计数。本研究所有检测到的变量中，依据预设阈值 ($P_{adj} < 10^{-5}$ 且 $|\log_2 FC| > 2$) 共筛选出 1927 个显著差异表达基因 (DEGs)。其中，1646 个基因表现为显著上调，281 个基因表现为显著下调。此外，有 5836 个基因仅在统计学上显著但变化倍数不足

(*P_{only}*), 437 个基因仅在倍数上达标但缺乏统计学意义 (*FC_{only}*), 其余 23465 个基因 (NS) 在两组间无显著差异。

附加代码如下:

```
1 library(dplyr)
2 res_classified <- res_final %>%
3   mutate(group = case_when(
4     padj < cut_off_pvalue & log2FoldChange > cut_off_logFC ~ "Up", # 右上:
      显著上调
5     padj < cut_off_pvalue & log2FoldChange < -cut_off_logFC ~ "Down", # 左
      上: 显著下调
6     padj < cut_off_pvalue & abs(log2FoldChange) <= cut_off_logFC ~ "P_only",
      # 中上: 仅P显著
7     padj >= cut_off_pvalue & abs(log2FoldChange) > cut_off_logFC ~ "FC_only"
      , # 左右下: 仅FC显著
8     TRUE ~ "NS" # 灰色: 均不显著
9   ))
10
11 gene_counts <- table(res_classified$group)
12 print(gene_counts)
```

其中, 依据 p 值从小到大排序, 上调和下调的各前十个显著差异表达基因的具体数据在此处展示:

表 1: 显著差异表达基因汇总表 (共 20 个: 10 Up, 10 Down)

Gene Symbol	$\log_2$ FoldChange	P-value	padj	Status
<i>Up-regulated Genes (Top 10)</i>				
GABRD	4.46	2.05e-117	7.38e-113	Up
PLVAP	2.90	1.55e-98	2.79e-94	Up
CDKN3	3.90	1.32e-94	1.58e-90	Up
CDC25C	4.35	6.26e-93	5.62e-89	Up
UBE2T	3.20	5.43e-92	3.90e-88	Up
CENPF	3.88	7.79e-91	3.99e-87	Up
NCAPG	3.32	3.16e-90	1.48e-86	Up
MELK	3.24	3.61e-90	1.54e-86	Up
TOP2A	3.84	7.15e-89	2.85e-85	Up
KIF2C	3.37	1.05e-88	3.79e-85	Up
<i>Down-regulated Genes (Top 10)</i>				
ADAMTS13	-2.84	1.22e-83	2.44e-80	Down
OIT3	-3.27	1.98e-70	1.27e-67	Down
STAB2	-4.82	6.66e-64	2.82e-61	Down
CCL23	-2.97	1.84e-61	6.97e-59	Down
CSRNP1	-2.26	3.22e-60	1.17e-57	Down
ECM1	-3.08	2.77e-59	9.53e-57	Down
CLEC4M	-4.26	1.02e-51	2.92e-49	Down
FCN2	-3.75	1.77e-49	4.88e-47	Down
CLEC4G	-4.18	4.96e-49	1.34e-46	Down
VIPR2	-2.29	1.56e-47	4.10e-45	Down

4.7 外部数据集验证

4.7.1 显著上调基因: GABRD

在统计结果中, GABRD 基因 (ENSG00000187730) 呈现出了显著上调。利用[gepia3 网站](#)进行外部数据集验证, 证明该基因的确在癌症患者体内显著上调。

经过调查发现, GABRD 基因 (Gamma-aminobutyric acid type A receptor delta subunit) 是编码 GABA_A 受体 δ (delta) 亚基的基因。GABRD 在肝细胞癌中上调, 可能因肿瘤细胞异常激活神经递质信号通路, 促进增殖

与存活；同时通过调节 PI3K/AKT 信号通路增强抗凋亡能力，并影响肿瘤免疫微环境，从而获得生长优势。




图 11: GABRD 运行界面




图 12: GABRD 差异表达分析结果分类统计

4.7.2 显著下调基因：ADAMTS13

在统计结果中，ADAMTS13 基因（ENSG00000160323）呈现出了显著下调。利用 [gepia3 网站](#) 进行外部数据集验证，证明该基因的确在癌症患者体内显著下调。

经过调查发现，ADAMTS13 (A Disintegrin And Metalloproteinase with Thrombospondin motifs 13) 是一种分泌型金属蛋白酶编码基因，主要在肝脏产生。ADAMTS13 在肝细胞癌中下调，因肝细胞功能丧失及分化降低导致其合成减少；同时肿瘤相关炎症与缺氧抑制其表达。其降低削弱对 vWF 的裂解，促进微血栓形成与肿瘤血管异常，利于肿瘤生长与转移。




图 13: ADAMTS13 运行界面




图 14: ADAMTS13 差异表达分析结果分类统计

4.8 拓展调研

进一步地，将前 10 个显著上调的基因利用 [gepia3 网站](#) 进行单变量分析 (Univariable Analysis)。发现基因差异表达的显著性和生存预后并不存在绝对的相关性。在前 10 个显著上调基因中，最为关键的预后危险因子为 KIF2C，其 Kaplan-Meier 生存曲线体现了高表达患者有更短的总生存期，这与 DEG 分析结果相呼应：




图 15: KIF2C Kaplan-Meier 生存曲线

结果显示，该基因风险倍数 (HR) 为 2.20。表明 KIF2C 高表达组的死亡风险是低表达组的 2.20 倍。其低表达组的中位生存期为 70.01 个月，高表达组骤降至 37.29 个月（几乎缩短了一半）。统计显著性 ($P < 0.001$): p 值和 $p(HR)$ 均远小于 0.05 (1.08×10^{-5})，说明两组之间的生存差异具有极强的统计学意义，而非随机误差。总结来说，KIF2C 是肝细胞癌 (LIHC) 的关键预后危险因子，具备高度的临床诊断与监测价值。

KIF2C 是驱动蛋白家族的一员，核心功能是调节微管的解聚。在 LIHC 细胞中，KIF2C 基因过表达会导致细胞周期的加速，促使癌细胞不受控制地增殖，同时在此过程中会增加染色体错配率，从而加剧肿瘤的异质性和进化能力。

5 讨论

5.1 出现的 bug 以及解决

在最开始的代码中，意外出现了结果中存在大量重复基因的问题，在我对 DEG 结果进行排序后输出的具体结果呈现如下：

[illegible]

这说明在代码的某一个步骤出现了错误。在将每一步结果依次输出对比以及重新检查代码后，发现问题为以下步骤：

进一步地，我对于该命令的含义进行了进一步的学习。`counts(dds)` 代表返回一个基因（行） $\times$ 样本（列）的矩阵，矩阵中的值是每个基因在每个样本中的表达量。`rowSums()` 命令是指在对每一行求和，得到一个向量。在代码中代表每个元素是该基因在所有样本中的总计数，因此 `rowSums(counts(dds) >= 10)` 符合本身的筛选目的。而 `rowSums(counts(dds) >= 10)` 则是先进行矩阵元素逐个比较，得到一个逻辑矩阵，判断每个基因在每个样本中表达量是否大于等于 10，而下一步求和则是在呈现每个基因在多少个样本中表达量大于等于 10。

5.2 limma 分析与 DEG 分析

两种方法利用了不同的数据分布的建模方法，DESeq2 基于负二项分布

模型，而 limma 基于线性模型。负二项分布通过准确估计离散参数，分辨生物学差异以及随机分布，产生的假阳性较少，而经验贝叶斯模型通过全基因的整体表现，得到一个“背景方差”，相比于前者，在小样本量中表现更为优异。由于 DESeq2 软件最为保守，所以算出来的 p 值通常比较大，这一点在进行外部数据集验证的时候也已经发现。

5.3 基因差异表达与生存预后

在拓展调研中提到，基因差异表达的显著性和生存预后并不存在绝对的相关性。基因差异表达着重于理解基因对于某一种癌症的功能相关性，然而生存预后分析聚焦于致病性。因此不难理解，一个基因在肿瘤中显著上调，只能说明它在肿瘤组织中活跃，而不一定是驱动生存差异的核心因子。在本研究中发现，GABRD 基因的显著表达强于 KIF2C 基因，但是生存预后分析却呈现出了不同的结果。虽然在大量文献中也提及了 GABRD 对于生存预后的重要意义，但仅从本研究结果出发分析，GABRD 编码 GABA_A 受体 δ 亚基，主要涉及神经信号调控，在肝癌中可能参与代谢或信号调节，而不是驱动肿瘤恶性行为的核心因子。但是 KIF2C 是微管去聚合酶，直接调控有丝分裂和细胞增殖，高表达会加快肿瘤生长和转移，因此会对生存预后影响更直接。

5.4 进一步研究方向

1. 多组学整合分析：可以在这个数据集的基础上，结合 RNA-seq、突变、甲基化等修饰的相关数据，分析几个重要基因的表达调控机制。
2. 单细胞测序数据分析：利用单细胞 RNA-seq 数据集 ([GEO 数据库](#))，分析 DEG 在不同肿瘤细胞亚群或免疫细胞中的特异表达，揭示细胞异质性。
3. 转录因子预测：结合公开 ChIP-seq 数据验证预测的转录因子结合位点。

6 补充信息

6.1 AI 使用说明

在本次实验中，向 AI 提供的 prompt 主要包括以下几个方面：

1. latex 格式美化类
2. 火山图绘制：“请给我一些代码建议，我希望能够在火山图上对一些基因进行特定标注”
3. symbol 转换：“请问如何能将基因编码变为基因名称”
4. 结果分析：“请帮我对比这两种代码在逻辑上是否存在问题”

6.2 与小组同学讨论

通过与本组李鉴哲同学进行讨论，对于代码中出现的 bug 进行了排查，并且对于结果的分析以及后续的拓展调研也有了更深入的理解。