

TCGA-LIHC 肿瘤/正常样本分类实验报告

学院：元培学院 姓名：高禹宸

2026 年 4 月 10 日

1 实验目的

本实验使用 TCGA GDC Liver Cancer 表达量数据，对肿瘤样本与正常样本进行二分类分析。实验目标包括：

- 掌握 TCGA 表达量矩阵的基本读取与样本类型识别方法；
- 掌握基于训练集进行差异基因筛选和特征选择的基本流程；
- 使用合适的机器学习方法完成肿瘤/正常样本分类；
- 通过可视化和评价指标理解模型结果及其局限性。

2 背景介绍

肝细胞癌是一种比较常见的恶性肿瘤。肿瘤样本和正常样本在基因表达水平上通常会有比较明显的差异，因此可以尝试用表达谱数据把它们区分开。本实验使用 TCGA-LIHC 的表达量矩阵，并根据 TCGA barcode 里的样本类型编码区分肿瘤样本和正常样本。其中：01 表示原发性肿瘤样本，11 表示正常组织样本，02 为其他类型样本，这部分不纳入本次分析。

本次实验也是对于机器学习方法的一次实践与了解。此方法将样本的特征和它对应的正确类别交给模型，让模型去学习两者之间的关系，进而做出我们所需要的预测。在这个实验里，输入特征是很多个基因的表达量，标签则是样本为肿瘤还是正常。整个机器学习流程为：整理数据，选择合适的方法训练模型，测试模型预测能力。

本实验利用决策树来做分类。决策树根据特征一步一步地做判断，把样本分到不同类别里。它的优点是结构清楚，容易解释，也方便看出哪些基因对分类更重要；但如果出现树长得太复杂的情况，可能会把训练数据记得太死，影响泛化能力。

3 实验方法

3.1 数据来源与样本筛选

本次实验使用文件 `TCGA-LIHC.star_counts (2).tsv.gz`。数据共有 60660 个基因条目和 424 个样本列。根据 TCGA barcode 第 14–15 位的样本类型编码进行分组：

- 01: Primary Tumor, 记为 Tumor
- 11: Solid Tissue Normal, 记为 Normal
- 02: 其他类型, 本实验不纳入建模

对应的 R 代码如下：

```
raw_df <- read.delim(gzfile("TCGA-LIHC.star_counts (2).tsv.gz"), check.names =
  FALSE)
ensembl_id <- sub("\\..*$", "", raw_df[[1]])
sample_ids <- colnames(raw_df)[-1]
sample_type_code <- substr(sample_ids, 14, 15)
keep_idx <- sample_type_code %in% c("01", "11")
labels <- factor(
  ifelse(sample_type_code[keep_idx] == "01", "Tumor", "Normal"),
  levels = c("Normal", "Tumor")
)
```

表 1: 原始样本类型统计

样本类型编码	分组	数量
01	Tumor	371
11	Normal	50
02	Other	3

最终用于分类的样本共有 421 个，其中 Tumor 371 个，Normal 50 个。

3.2 数据预处理

预处理步骤如下：

- 读取表达矩阵，提取 Ensembl ID，并去除版本号后缀；
- 仅保留样本类型编码为 01 和 11 的样本；

- 以样本为行、基因为列构建机器学习输入矩阵；
- 使用 `bitr()` 和 `org.Hs.eg.db` 将 Ensembl ID 尽可能转换为基因 Symbol，用于结果展示和图像标注。

对应的 R 代码如下：

```
expr_mat <- as.matrix(raw_df[, -1, drop = FALSE])[, keep_idx, drop = FALSE]
rownames(expr_mat) <- ensembl_id

gene_map <- bitr(
  unique(ensembl_id),
  fromType = "ENSEMBL",
  toType = "SYMBOL",
  OrgDb = org.Hs.eg.db,
  drop = FALSE
)
colnames(gene_map)[colnames(gene_map) == "ENSEMBL"] <- "ENSEMBL_clean"
```

3.3 数据分割

采用分层抽样的方式进行 7:3 训练集/测试集划分，以保证训练集和测试集中都保留肿瘤与正常样本。

对应的 R 代码如下：

```
set.seed(20260403)
train_idx <- unlist(
  tapply(seq_along(labels), labels, function(i) sample(i, ceiling(length(i) *
    0.7)))
)
test_idx <- setdiff(seq_along(labels), train_idx)

train_expr <- expr_mat[, train_idx, drop = FALSE]
test_expr <- expr_mat[, test_idx, drop = FALSE]
train_labels <- labels[train_idx]
test_labels <- labels[test_idx]
```

表 2: 训练集与测试集样本统计

数据集	Tumor	Normal	合计
Training	260	35	295
Testing	111	15	126

3.4 特征选择

为避免信息泄漏，先划分训练集与测试集，再仅在训练集上进行差异表达分析。具体做法如下：

- 对每个基因在 Tumor 与 Normal 之间做 Welch t 检验；
- 使用 Benjamini-Hochberg 方法对 p 值进行多重检验校正；
- 按校正后 p 值从小到大排序，并结合 $|LogFC|$ 进行筛选；
- 取前 50 个差异表达最显著的基因作为模型输入特征。

对应的 R 代码如下：

```
tumor_mean <- rowMeans(train_expr[, train_labels == "Tumor", drop = FALSE])
normal_mean <- rowMeans(train_expr[, train_labels == "Normal", drop = FALSE])
log_fc <- tumor_mean - normal_mean
p_value <- apply(train_expr, 1, function(v) {
  t.test(v[train_labels == "Tumor"], v[train_labels == "Normal"])$p.value
})
padj <- p.adjust(p_value, method = "BH")

de_table <- data.table(
  Gene = rownames(train_expr),
  LogFC = log_fc,
  PValue = p_value,
  Padj = padj
)
setorder(de_table, Padj, -abs(LogFC))
top50_genes <- de_table$Gene[1:50]
```

3.5 模型训练

本实验的建模流程比较直接：先把样本按类别分开抽样，再只在训练集里筛选 Top50 差异表达基因，最后用这些基因训练二分类决策树模型。

模型训练参数设置为:

- `method = "class"`, 用于二分类;
- `cp = 0.001`;
- `maxdepth = 5`;
- `minbucket = 4`;
- 使用平衡先验概率 `prior = c(0.5, 0.5)`, 减轻类别不平衡影响。

对应的 R 代码如下:

```
train_df <- data.frame(Class = train_labels, t(train_expr[top50_genes, , drop
  = FALSE]))
test_df <- data.frame(Class = test_labels, t(test_expr[top50_genes, , drop =
  FALSE]))

tree_model <- rpart(
  Class ~ .,
  data = train_df,
  method = "class",
  parms = list(prior = c(0.5, 0.5)),
  control = rpart.control(cp = 0.001, maxdepth = 5, minbucket = 4)
)
```

4 实验结果

4.1 差异表达基因结果

训练集中前 10 个差异表达基因如下表所示。这些基因在 Tumor 与 Normal 之间具有较明显的表达差异, 可作为后续分类模型的重要输入特征。

表 3: 训练集中前 10 个差异表达基因

Gene Symbol	LogFC	PValue	Padj
GDF2	-8.2757	4.14E-86	2.31E-81
SFTA1P	3.2325	1.33E-78	3.73E-74
CXCL14	-6.2229	3.87E-77	7.21E-73
SFRP5	-6.2469	6.00E-73	8.37E-69
CHST4	-5.6493	8.43E-69	9.39E-65
COLEC10	-5.4778	1.01E-68	9.39E-65
SLC5A1	-5.0420	2.87E-65	2.29E-61
BMP10	-6.8837	1.39E-63	9.69E-60
SLC25A47	-4.9568	2.63E-61	1.63E-57
ENSG00000243694	-4.6418	7.04E-60	3.93E-56




图 1: 前 10 个差异表达基因可视化

从图中可以看出，这些基因在 Tumor 与 Normal 间的表达差异方向并不完全一致，其中部分基因在正常样本中表达更高，部分基因在肿瘤样本中表达更高，这说明分类信息并不是由单一方向的表达变化决定，而是由多基因组合共同决定。

4.2 样本分布的 PCA 结果




图 2: Top50 差异基因的 PCA 可视化

PCA 结果显示，肿瘤样本与正常样本在前两个主成分空间中已经出现较明显分离，说明筛选出的差异基因具有较好的判别能力。

4.3 决策树结构与重要变量




图 3: 决策树变量重要性前 10 基因




图 4: 决策树结构图

根据变量重要性结果,排名靠前的基因包括 $GDF2$ 、 $BMP10$ 、 $FCN2$ 、 $COLEC10$ 和 $CLEC4M$ 。这些基因在决策树中被频繁用于分裂节点,说明它们对区分肿瘤与正常样本的贡献较大。

5 讨论

5.1 为何选择这种方法

这次选择决策树作为主要分类方法,主要有下面几个原因:

- 决策树可直接处理多维表达特征,且不要求特征之间满足线性关系;
- 模型结构直观,便于解释哪些基因在分类中更重要;
- 对于本次样本量不大、特征数经筛选后为 50 的数据,决策树实现简单且适合课程实验要求。

5.2 模型评价

本实验是在独立测试集上做模型评价的。为了不只看一个准确率,这里还一起计算了 Precision、Recall、Specificity、F1 和 AUC。

这些指标分别反映了模型不同方面的表现：Accuracy 表示整体分对了多少；Precision 表示被判成肿瘤的样本里有多少是真的肿瘤；Recall 表示所有真实肿瘤里有多少被成功识别出来；Specificity 表示所有真实正常样本里有多少被正确分成正常；F1 是 Precision 和 Recall 的综合指标；AUC 则反映模型整体区分两类样本的能力。

表 4: 决策树模型在测试集上的评价指标

Accuracy	Precision	Recall	Specificity	F1	AUC
0.8730	0.9524	0.9009	0.6667	0.9259	0.7838

表 5: 测试集混淆矩阵

实际类别	预测为 Normal	预测为 Tumor
Normal	10	5
Tumor	11	100

从混淆矩阵可以看出，模型对肿瘤样本的识别效果比较好，肿瘤样本的召回率达到 0.9009；但对正常样本的识别相对弱一些，仍有 5 个正常样本被错分成肿瘤，所以 Specificity 只有 0.6667。出现这种情况的一个重要原因是原始数据里肿瘤样本远多于正常样本，模型更容易偏向肿瘤这一类。




图 5: 决策树模型 ROC 曲线

ROC 曲线对应的 AUC 为 0.7838，说明模型已经有一定的区分能力，明显好于随机猜测，但还谈不上特别理想，后面还有继续优化的空间。

5.3 训练集选取基因的随机性及其影响

这次实验是先随机划分训练集和测试集，再只在训练集里筛选 Top50 差异表达基因。因为训练集本身就是随机抽出来的，所以只要随机种子不同，进入训练集的样本组合就会变，最后筛出来的 Top50 基因也不一定完全一样。

这会带来两个比较直接的影响。第一，不同训练次数下得到的前 10 个差异基因和 Top50 特征集可能会有一些变化，尤其是排在边界附近的基因更容易被替换。第二，模型是基于这些特征训练出来的，所以不同训练次数下的分类结果也可能会波动，比如 Accuracy、AUC 或变量重要性排序都会有一些变化。

所以，这次实验得到的结果更适合理解为“在当前这一次随机划分下得到的可复现实验结果”，而不是一个完全固定不变的结论。如果能让结果更稳一些，后面可以考虑做重复随机划分、交叉验证，或者固定多个随机种子反复实验后再取平均。

5.4 实验的不足与可改进方向

这次实验还有几个比较明显的不足。首先，正常样本数明显少于肿瘤样本，类别不平衡会影响模型对正常样本的识别能力。其次，这里只做了一次训练集/测试集划分，所以结果会受到随机性的影响。再次，决策树虽然好解释，但泛化能力不一定比更强的集成方法更好。

后面如果继续做，可以尝试随机森林、支持向量机或者 XGBoost 这类方法，再结合交叉验证来得到更稳定的性能估计。另外，也可以把标准差异分析和机器学习里的特征筛选分得更清楚一些，这样结果解释会更自然。

6 引用

6.1 数据集与软件

- 数据集: TCGA-LIHC 表达量数据, 文件为 TCGA-LIHC.star_counts (2).tsv.gz。
- 软件环境: R 4.5.2。
- 主要 R 包: data.table 1.17.8, rpart 4.1.24, ggplot2 4.0.0, dplyr 1.1.4, tibble 3.3.0, clusterProfiler 4.18.4, org.Hs.eg.db 3.22.0。

6.2 AI 使用说明

本实验在代码整理、报错排查、图表标签优化和实验报告撰写过程中使用了 AI 辅助。AI 主要帮助完成了以下工作:

- 协助生成和修改 R 脚本, 包括按样本类型区分肿瘤与正常样本、训练决策树模型, 以及输出混淆矩阵、ROC 曲线和变量重要性图;

- 在代码运行过程中辅助分析报错原因并调整实现方式，例如基因 ID 转换、图像标签优化和 LaTeX 报告结构调整；
- 根据实验结果协助整理实验报告内容，使报告结构更符合实验报告范例要求。

需要说明的是，AI 主要作为辅助工具使用。所有代码均在本地环境中实际运行，所有结果、图表和表格均以本地运行输出为准；实验内容的组织、结果理解和最终表述经过了人工检查和修改。

6.3 代表性提示词

- 仅基于训练集筛选 Top50 差异表达基因。
- 将 Ensembl ID 尽可能转换为基因名称，并在显著基因图和变量重要性图中优先显示基因名称。
- 套用更加规范的 LaTeX 模板。