

Linux 基础与 ANNOVAR FASTA 序列统计实验报告

学院：元培学院 姓名：高禹宸
学号：2400017417 班级：周二班

2026 年 4 月 30 日

1 实验目的

本实验依据课程 PDF 《Introduction to Linux for Biological Sciences》完成 Linux 基础操作与 ANNOVAR FASTA 文件分析。主要目标包括：

- 掌握 Linux/macOS 终端中的目录创建、路径切换、文件复制、删除、解压和帮助查询；
- 安装并检查基因组注释工具 ANNOVAR，理解其示例目录和 FASTA 文件格式；
- 使用 grep、wc、重定向、Bash 脚本等工具统计特定染色体上的 RNA 序列数量；
- 比较所有常染色体 RNA 序列数量，并用 R 可视化其与染色体长度之间的关系；
- 讨论 RNA 序列数量是否与染色体长度成比例，以及可能影响这种关系的因素。

2 背景介绍

Linux 命令行是生物信息学实验中常用的数据处理环境。相比图形界面，命令行更适合处理大规模文本文件、批量运行程序和构建可复现分析流程。本实验使用的 ANNOVAR 是常见的基因组注释工具，其示例数据中包含多个标准生物信息学文件，例如 VCF、avinput、GFF 和 FASTA 文件。

FASTA 文件通常由描述行和序列行组成。描述行以 “>” 开头，后续为核酸或蛋白质序列。本次实验分析的文件为 hg38_refGeneWithVerMrna.fa，其中描述行包含 RefGene 转录本编号、染色体位置和 ANNOVAR 生成信息。通过筛选描述行中染色体位置字段，可以统计不同染色体上的 RNA 序列数量。

3 实验材料与方法

3.1 实验材料

表 1: 实验材料与文件

材料	文件或来源	用途
课程说明	c4.Linux_basics.pdf	实验要求与得分点
终端记录	终端保存的输出.txt	课堂已完成命令和结果
分析软件	annovar.latest.tar.gz	ANNOVAR 安装包
FASTA 文件	hg38_refGeneWithVerMrna.fa	RNA 序列统计
染色体长度	GRCh38 chromosome lengths	长度与 RNA 序列数量比较

3.2 总体分析流程

本实验的整体流程为：创建课程目录，复制并删除 ANNOVAR 压缩包进行文件操作练习，解压 ANNOVAR，查看 README 和 FASTA 文件，筛选 chr21 序列描述行，编写 Bash 脚本统计 chr21 和所有常染色体 RNA 序列数量，最后用 R 绘图并讨论染色体长度与 RNA 序列数量的关系。

4 逐项实验结果

本节按照课程 PDF 中的每个得分点分别展示。每一项均包括得分点要求、Linux 代码、终端或文件结果以及结果说明。

4.1 创建课程目录并验证当前位置（1 分）

得分点要求：从 home 目录开始，创建课程文件夹 bioinfor，进入该目录，并用 pwd 验证。

Linux 代码：

```
cd ~
mkdir /Users/gaoyuchen/Desktop/bioinfor
cd /Users/gaoyuchen/Desktop/bioinfor
pwd
```

实验结果：

```
/Users/gaoyuchen/Desktop/bioinfor
```

该结果说明课程目录创建成功，并且当前工作目录已经切换到 bioinform。

4.2 复制 ANNOVAR 压缩包并用 ls 验证 (0.5 分)

得分点要求：将 ANNOVAR 安装包复制到课程目录，并用 ls 查看是否复制成功。

Linux 代码：

```
cp /Users/gaoyuchen/Desktop/homework4/annovar.latest.tar.gz /Users/gaoyuchen
/Desktop/bioinform
ls /Users/gaoyuchen/Desktop/bioinform
```

实验结果：

```
annovar.latest.tar.gz
```

ls 输出中出现 annovar.latest.tar.gz，说明压缩包已复制到课程目录。

4.3 用 bash 删除复制出的压缩包并验证 (0.5 分)

得分点要求：使用 rm 删除课程目录中的压缩包，并再次用 ls 验证。

Linux 代码：

```
rm /Users/gaoyuchen/Desktop/bioinform/annovar.latest.tar.gz
ls /Users/gaoyuchen/Desktop/bioinform
```

实验结果：

```
# 无输出
```

删除后 ls 没有显示文件，说明该压缩包已从课程目录删除。

4.4 运行并解释 tar 解压命令 (1 分)

得分点要求：运行并解释 tar -zxvf annovar.latest.tar.gz，写明帮助来源。

Linux 代码：

```
tar --help
tar -zxvf /Users/gaoyuchen/Desktop/bioinform/annovar.latest.tar.gz
```

实验结果节选：

```
x annovar/
x annovar/example/
x annovar/example/ex1.avinput
```

```
x annovar/example/README
x annovar/humandb/
x annovar/humandb/hg38_refGeneWithVerMrna.fa
x annovar/annotate_variation.pl
x annovar/table_annovar.pl
```

帮助来源为 `tar --help`。-x 表示解包，-z 表示通过 gzip 解压，-v 表示显示处理过程，-f 表示指定压缩包文件。终端输出显示 ANNOVAR 目录、示例文件和 humandb 数据库文件均被解压。

4.5 用 cat 查看 ANNOVAR README

得分点要求：使用 cat 查看小文本文件，理解 ANNOVAR 示例目录中的文件说明。

Linux 代码：

```
cat /Users/gaoyuchen/Desktop/bioinfor/annovar/example/README
```

实验结果节选：

```
visit ANNOVAR website at http://www.openbioinformatics.org/annovar for more
example.

ex1.avinput: a simple ANNOVAR input example with a few variants
ex2.vcf: a simple VCF file with genotype information for 3 samples
gene_xref.txt: an example gene cross-reference file
humandb/hg19_example_db_generic.txt: an example file for generic database
```

README 文件说明了 ANNOVAR 示例数据中 avinput、VCF、gene cross-reference 和示例数据库文件的用途。

4.6 用 less 查看 FASTA 并搜索 chr22 (1 分)

得分点要求：使用 less 查看大 FASTA 文件，并在 less 中搜索 chr22。

Linux 代码：

```
less /Users/gaoyuchen/Desktop/bioinfor/annovar/humandb/
    hg38_refGeneWithVerMrna.fa
# 在 less 中输入：
/chr22
# 按 n 查看下一个匹配，按 q 退出
```

实验结果示意：

```
>NM_... Comment: this sequence (leftmost exon at chr22:...) is generated by
ANNOVAR ...
```

FASTA 文件较大, 不适合一次性用 `cat` 全部输出; `less` 可以分页查看并用 `/chr22` 搜索包含 `chr22` 的序列描述行。

4.7 筛选 chr21 行并导出为 hg38_chr21.txt (1 分)

得分点要求: 在 FASTA 文件中筛选包含 `chr21` 的行, 输出到 `hg38_chr21.txt`, 并查看新文件。

Linux 代码:

```
grep "chr21" /Users/gaoyuchen/Desktop/bioinform/annovar/humandb/
hg38_refGeneWithVerMrna.fa > hg38_chr21.txt
cat hg38_chr21.txt
mv /Users/gaoyuchen/hg38_chr21.txt /Users/gaoyuchen/Desktop/bioinform
wc -l /Users/gaoyuchen/Desktop/bioinform/hg38_chr21.txt
head -n 3 /Users/gaoyuchen/Desktop/bioinform/hg38_chr21.txt
```

实验结果:

```
1121 /Users/gaoyuchen/Desktop/bioinform/hg38_chr21.txt
>NR_104257.2 Comment: this sequence (leftmost exon at chr21:41798224) ...
>NM_001001438.2 Warning: ... (leftmost exon at chr21:46188445) ...
>NM_004571.5 Comment: this sequence (leftmost exon at chr21:42974561) ...
```

输出文件 `bioinform/hg38_chr21.txt` 共 1121 行, 说明筛选出的 `chr21` 相关描述行数量为 1121。

4.8 Bash 脚本统计 chr21 序列数量 (1 分)

得分点要求: 脚本接受一个 FASTA 格式文件作为输入, 输出 `chr21` 上的 RNA 序列数量。

Linux 代码:

```
#!/bin/bash

file="$1"
grep -c ">.*chr21" "$file"

chmod +x count_chr21.sh
```

```
./count_chr21.sh /Users/gaoyuchen/Desktop/bioinfor/annovar/humandb/  
hg38_refGeneWithVerMrna.fa
```

实验结果：

```
1121
```

脚本输出 1121，与 hg38_chr21.txt 的行数一致。

4.9 在脚本中检查输入文件是否存在（1 分）

得分点要求：在上一题脚本基础上，加入输入文件存在性判断。

Linux 代码：

```
#!/bin/bash  
  
file="$1"  
if [ ! -f "$file" ]; then  
    echo "Error: input FASTA file does not exist."  
    exit 1  
fi  
  
grep -c ">.*leftmost exon at chr21[:_]" "$file"
```

实验结果：

```
# 输入正确文件时：  
1121  
  
# 输入不存在文件时：  
Error: input FASTA file does not exist.
```

使用 -f 判断输入是否为普通文件，可以避免空参数或错误路径导致 grep 报错。

4.10 循环比较所有常染色体 RNA 序列数量（1 分）

得分点要求：在上一题基础上，用循环统计 chr1 到 chr22 的 RNA 序列数量。

Linux 代码：

```
#!/bin/bash  
  
file="$1"  
if [ ! -f "$file" ]; then
```

```
    echo "Error: input FASTA file does not exist."
    exit 1
fi

for i in {1..22}; do
    chr="chr${i}"
    count=$(grep -c "^>.*leftmost exon at ${chr}[:_]" "$file")
    printf "%s\t%s\n" "$chr" "$count"
done
```

实验结果:

```
chr1 7845
chr2 5583
chr3 4943
chr4 3024
chr5 3689
chr6 6988
chr7 3989
chr8 3094
chr9 3063
chr10 3611
chr11 4869
chr12 3977
chr13 1510
chr14 2546
chr15 3002
chr16 3400
chr17 4615
chr18 1279
chr19 6909
chr20 1970
chr21 1121
chr22 1863
```

统计结果已保存为 `report/chr_sequence_counts_autosomes.csv`, 用于后续 R 可视化和相关性分析。

4.11 使用 R 可视化结果 (1 分)

得分点要求：使用 R 可视化所有染色体 RNA 序列数量，并比较常染色体长度与 RNA 序列数量。

Linux 代码：

```
Rscript report/make_chr_analysis.R
```

R 脚本内容 (make_chr_analysis.R):

```
input <- "bioinfor/annovar/humandb/hg38_refGeneWithVerMrna.fa"

headers <- readLines(input, warn = FALSE)
headers <- headers[startsWith(headers, ">")]

chr <- sub(".*leftmost exon at (chr[0-9XY]+)[:_].*", "\\1", headers)
chr <- chr[grepl("^chr([1-9]|1[0-9]|2[0-2]|X|Y)$", chr)]

counts <- as.data.frame(table(chr), stringsAsFactors = FALSE)
names(counts) <- c("chromosome", "rna_sequence_count")
counts$chr_order <- match(counts$chromosome, c(paste0("chr", 1:22), "chrX",
"chrY"))
counts <- counts[order(counts$chr_order), c("chromosome", "
rna_sequence_count")]

lengths <- data.frame(
  chromosome = paste0("chr", 1:22),
  length_bp = c(
    248956422, 242193529, 198295559, 190214555, 181538259, 170805979,
    159345973, 145138636, 138394717, 133797422, 135086622, 133275309,
    114364328, 107043718, 101991189, 90338345, 83257441, 80373285,
    58617616, 64444167, 46709983, 50818468
  )
)

autosomes <- merge(counts, lengths, by = "chromosome")
autosomes$chr_num <- as.integer(sub("chr", "", autosomes$chromosome))
autosomes <- autosomes[order(autosomes$chr_num), ]
autosomes$length_mb <- autosomes$length_bp / 1e6
autosomes$rna_per_mb <- autosomes$rna_sequence_count / autosomes$length_mb
autosomes <- autosomes[, c("chromosome", "length_bp", "length_mb", "
```



```
    rna_sequence_count", "rna_per_mb"]])

write.csv(counts, "report/chr_sequence_counts_all.csv", row.names = FALSE)
write.csv(autosomes, "report/chr_sequence_counts_autosomes.csv", row.names =
  FALSE)

cor_value <- cor(autosomes$length_mb, autosomes$rna_sequence_count)
sink("report/correlation_summary.txt")
cat(sprintf("Pearson correlation between autosome length and RNA sequence
  count: %.3f\n", cor_value))
cat(sprintf("chr21 RNA sequence count: %d\n", counts$rna_sequence_count[
  counts$chromosome == "chr21"]))
sink()

png("report/chr_length_vs_rna_count.png", width = 1800, height = 1200, res =
  180)
par(mar = c(5, 5, 3, 1))
plot(
  autosomes$length_mb,
  autosomes$rna_sequence_count,
  pch = 19,
  col = "#2F6F73",
  xlab = "Chromosome length (Mb)",
  ylab = "RNA sequence count",
  main = "RNA sequence count vs. chromosome length (autosomes)"
)
text(
  autosomes$length_mb,
  autosomes$rna_sequence_count,
  labels = autosomes$chromosome,
  pos = 3,
  cex = 0.72,
  col = "#333333"
)
fit <- lm(rna_sequence_count ~ length_mb, data = autosomes)
abline(fit, col = "#C55A11", lwd = 2)
legend(
  "topleft",
  legend = sprintf("Pearson r = %.3f", cor_value),
```

```
    bty = "n",
    text.col = "#333333"
)
dev.off()

png("report/chr_rna_counts_barplot.png", width = 1800, height = 1000, res =
    180)
par(mar = c(5, 5, 3, 1))
barplot(
    counts$rna_sequence_count,
    names.arg = counts$chromosome,
    col = "#7FA8A9",
    border = NA,
    las = 2,
    ylab = "RNA sequence count",
    main = "RNA sequence count by chromosome"
)
dev.off()
```

实验结果：

生成文件：

- report/chr_rna_counts_barplot.png
- report/chr_length_vs_rna_count.png
- report/chr_sequence_counts_all.csv
- report/chr_sequence_counts_autosomes.csv
- report/correlation_summary.txt




图 1: 各染色体 RNA 序列数量统计




图 2: 常染色体长度与 RNA 序列数量关系

4.12 讨论 RNA 序列数量是否与染色体长度成比例 (1 分)

得分点要求: 结合可视化结果, 讨论每条染色体 RNA 序列数量是否与 DNA 长度成比例, 并分析影响因素。

Linux 代码:

```
cat report/correlation_summary.txt
```

实验结果：

```
Pearson correlation between autosome length and RNA sequence count: 0.572  
chr21 RNA sequence count: 1121
```

常染色体长度与 RNA 序列数量存在中等正相关，但并不严格成比例。如果二者严格成比例，散点图中的点应大致沿一条直线分布；实际结果中 chr19 长度较短却有较高 RNA 序列数，而 chr13、chr18 等染色体的 RNA 序列数量相对较低。这说明染色体 DNA 长度不能单独解释 RNA 序列数量。

可能影响该关系的因素包括基因密度、可变剪接产生的多个转录本、非编码 RNA 注释密度、重复序列和异染色质比例、参考注释数据库的完整程度，以及替代单倍型或未放置序列是否被纳入统计。因此，本实验中的 RNA 序列数量更接近基因和转录本注释密度的结果，而不是简单由染色体长度决定。

5 综合结果

表 2: 常染色体 RNA 序列数量与染色体长度

染色体	长度/Mb	RNA 序列数	每 Mb 序列数
chr1	248.96	7845	31.51
chr2	242.19	5583	23.05
chr3	198.30	4943	24.93
chr4	190.21	3024	15.90
chr5	181.54	3689	20.32
chr6	170.81	6988	40.91
chr7	159.35	3989	25.03
chr8	145.14	3094	21.32
chr9	138.39	3063	22.13
chr10	133.80	3611	26.99
chr11	135.09	4869	36.04
chr12	133.28	3977	29.84
chr13	114.36	1510	13.20
chr14	107.04	2546	23.78
chr15	101.99	3002	29.43
chr16	90.34	3400	37.64
chr17	83.26	4615	55.43
chr18	80.37	1279	15.91
chr19	58.62	6909	117.87
chr20	64.44	1970	30.57
chr21	46.71	1121	24.00
chr22	50.82	1863	36.66

6 结论

本实验完成了 Linux 基础文件操作、ANNOVAR 解压与示例文件查看、FASTA 文件筛选、Bash 脚本统计和 R 可视化分析。主要结论如下：

- ANNOVAR 已成功解压，并可以查看 example 目录和 humandb FASTA 文件；
- FASTA 描述行以 “>” 开头，包含转录本编号和染色体位置信息；
- hg38_refGeneWithVerMrna.fa 中 chr21 相关 RNA 序列描述行为 1121 条；

- chr1–chr22 的 RNA 序列数量差异明显, chr1、chr6、chr19 数量较高, chr18、chr21 较低;
- 常染色体长度与 RNA 序列数量的 Pearson 相关系数为 0.572, 说明二者有一定正相关, 但并不严格成比例。

7 引用与 AI 使用说明

7.1 数据集与软件

- 课程材料: `c4.Linux_basics.pdf`。
- 分析软件: ANNOVAR。
- 输入文件: `bioinfor/annovar/humandb/hg38_refGeneWithVerMrna.fa`。
- 软件环境: macOS 终端、Bash、R 4.5.2、 $\text{\LaTeX}$ 。

7.2 AI 使用说明

本实验在课程 PDF 阅读、终端记录整理、结果文件汇总、R 可视化脚本补充和实验报告排版过程中使用了 AI 辅助。AI 的主要用途包括:

- 根据课程 PDF 提取实验要求和得分点;
- 根据 终端保存的输出 `.txt` 整理已完成的 Linux 命令和结果;
- 补充常染色体 RNA 序列统计、相关性分析和可视化;
- 按照既往实验报告 PDF 的 $\text{\LaTeX}$ 风格整理本次实验报告。

需要说明的是, 所有统计结果、图表和文件均基于本地工作目录中的实际文件生成; 最终报告内容经过人工检查和修改。

7.3 代表性提示词

- 阅读这个文档里的 PDF, 了解此次生信实验课程需要的东西, 帮我完成并输出一份实验报告。
- 期中 `txt` 文件是我课上已经用终端完成的内容, 需要导出的结果应该也在其中的某个文件夹里面, 你自行整理一下, 我完成的部分可以直接用。
- 我希望按照 PDF 里每个地方的得分点都展示出来。

- 每一分给我写成一个单独实验结果，包括 Linux 代码和结果。
- 按照之前实验报告 PDF 的格式整理，变成 LaTeX 输出 PDF。